

Validacao — Features de Satelite vs. Baseline M1

Indice de densidade urbana construida e vetor de crescimento por hexagono H3

Brasil de mercado — 12 UFs · 486.850 hexagonos H3 res 7 (~5,16 km²)

Autor: Juan Lima · Data: 2026-07-13 · Documento independente

Sumario executivo

O baseline atual do M1 e' CEGO DENTRO DO MUNICIPIO. O score que hoje prioriza sites e' constante para todos os hexagonos de um mesmo municipio — e' um numero municipal pintado no mapa. Medimos o custo disso: 68,2% da variacao da densidade construida e 76,8% da variacao do crescimento acontecem DENTRO dos municipios, ou seja, sao invisiveis a triagem atual.

A nuance honesta: em metropoles compactas e totalmente urbanizadas (Sao Paulo, Rio), o valor unico do M1 aproxima bem. A cegueira se concentra nos municipios de GRANDE AREA, que misturam nucleo urbano e vazio rural — ou seja, exatamente onde esta a fronteira de expansao.

O satelite entrega 125x mais resolucao (486.850 hexagonos contra 3.892 municipios) e uma dimensao que o Censo nao tem: TEMPO. O ganho nao e' marginal — e' uma camada de informacao inteira.

1. O que esta sendo entregue

Dois datasets hex-level prontos para consumo (486.850 hexagonos, 12 UFs, H3 resolucao 7):

- `indice_densidade_construida_BR` — densidade urbana construida por hexagono: fracao construida em 2016 e 2023, altura media e indice 0-100 (percentil nacional).
- `vetor_crescimento_hex_BR` — crescimento 2016→2023 por hexagono: delta, variacao %, classe (expansao forte / expansao / estavel / retracao) e o VETOR de crescimento (direcao em graus e magnitude), obtido do gradiente local na malha H3.
- `candidatos_ocultos_BR` — hexagonos onde o satelite ve construcao alta e o M1 pontua baixo.

Escopo, com honestidade: 'todo o Brasil' aqui significa o Brasil DE MERCADO — os 12 estados que concentram a demanda (Sudeste e Sul completos, capitais/RMs do Nordeste, Centro-Oeste). Interior Norte/Nordeste e Amazonia ficaram de fora por ausencia de mercado, nao por limite tecnico: o pipeline roda em qualquer UF quando necessario. Custo de dados: zero.

2. Achado central — o baseline nao tem resolucao intramunicipal

Ao tentar medir o ganho preditivo das features de satellite, encontramos primeiro uma propriedade estrutural do baseline que a lideranca precisa conhecer:

Evidencia	Medida
Municipios (com >1 hex) cujo score M1 e' constante em TODOS os seus hexagonos	3.890 de 3.890 (100%)
R ² para recuperar o score M1 usando SO renda + populacao (RandomForest, CV)	1,000 (ajuste perfeito)
Resolucao efetiva do baseline M1	3.892 unidades (municipios)
Resolucao do satellite	486.850 hexagonos (125x)


Leitura: renda e populacao no M1 sao valores MUNICIPAIS, e o score e' uma formula deterministica deles. Portanto o score nao varia entre o centro e a periferia da mesma cidade, nem entre um bairro adensado e um hexagono rural vazio do mesmo municipio.

Custo medido dessa cegueira: 68,2% da variancia da densidade construida e 76,8% da variancia do crescimento sao INTRAMUNICIPAIS — estruturalmente irrepresentaveis pelo baseline atual.

Onde essa cegueira doi (e onde nao doi) — uma nuance importante e honesta: em metropoles COMPACTAS e integralmente urbanizadas (Sao Paulo, Rio, Belo Horizonte), quase todo hexagono e' denso, e o valor unico do M1 e' uma aproximacao razoavel. O baseline colapsa nos municipios de GRANDE AREA, que misturam nucleo urbano e vazio rural — precisamente onde fica a fronteira de expansao. A dispersao interna cresce com a area do municipio:

Quartil de area do municipio	Municipios	Hexes (mediana)	Dispersao interna IQR	Amplitude p05-p95
Q1 (menor area)	973	24	14,6	40,7
Q2	973	50	22,9	59,3
Q3	973	93	28,5	68,9
Q4 (maior area)	973	235	32,8	71,9

Em numeros: nos municipios do quartil de maior area, metade dos hexagonos se espalha por mais de 30 pontos de percentil de densidade, e a amplitude tipica chega a ~69 pontos — e o M1 atribui UM unico numero a todos eles.



A esquerda, metropoles compactas: o satellite ve densidade uniformemente alta e o valor unico do M1 aproxima bem. A direita, municipios de grande area: o satellite ve um espectro de 0 a 100, e o unico numero do M1 perde a informacao que importa.

3. Por que o teste classico de 'ganho de R^2 ' e' vazio aqui

A validacao usual seria medir quanto as features de satellite aumentam o R^2 na previsao do score do M1. Como o score e' uma formula fechada de renda+populacao ($R^2 = 1,000$), NENHUMA feature — de satellite ou de qualquer fonte — pode aumentar esse R^2 . O ganho incremental e' zero por construcao matematica, nao por fraqueza do satellite. Apresentar ' $\Delta R^2 = 0$ ' como ausencia de valor seria estatisticamente desonesto.

A pergunta correta nao e' 'o satellite preve melhor o score do M1?' — e sim 'o que o M1 nao consegue ver, e o satellite ve?'. Os testes 4 e 5 respondem isso.

4. Teste — o crescimento e' informacao nova (nao redundante)

Se a feature de crescimento fosse redundante com o baseline, teria correlacao alta com o score do M1. Ela nao tem:

Relacao	Correlacao	Leitura
Crescimento (satellite) x score M1	0,180	Quase ortogonal — informacao nova
Crescimento (satellite) x populacao M1	0,216	Nao e' explicado pela populacao
Densidade (satellite) x	0,351	Corrobora o sinal de


populacao M1		mercado
Densidade (satelite) x score M1	0,180	Medida fisica independente
Crescimento x Densidade (satelite)	0,808	Coerencia interna do satelite

Com correlacao de apenas 0,18 contra o score, cerca de 97% da variacao do crescimento construido nao e' capturada pelo baseline. Essa e' a definicao operacional de ganho real: sinal que a triagem de hoje nao possui.

5. Teste — divergencia: a fila de candidatos que o M1 descarta

39.873 hexagonos (8,19% do total) estao entre os 20% mais densos pelo satelite enquanto o M1 os coloca na metade inferior do ranking.

UF	Candidatos ocultos
MG	8.198
RS	7.029
BA	4.914
PR	4.362
SC	4.315
SP	3.664
CE	2.703
PE	2.174
GO	1.213
ES	967
RJ	334



Cada ponto e' um hexagono. As faixas verticais sao o proprio sintoma: o score M1 assume poucos valores distintos (um por municipio).

Lista completa em candidatos_ocultos_BR.csv (hex_id, municipio, UF, densidade, score M1, divergencia).

6. Cobertura por estado

UF	Hexagonos	Densidade media 2023	% hexes que cresceram
MG	104.078	0,0029	72,8%
BA	94.279	0,0016	74,5%
RS	62.410	0,0037	64,2%
GO	59.954	0,0019	67,3%
SP	47.389	0,0109	64,0%
PR	40.481	0,0053	68,4%
CE	24.192	0,0036	71,5%
SC	20.373	0,0078	79,7%
PE	16.085	0,0048	79,7%
ES	8.324	0,0055	92,3%
RJ	8.286	0,0162	74,0%
DF	999	0,0219	76,2%

7. Limites honestos desta validacao

- Não foi possível validar contra o desempenho real das unidades da Ultra: apenas 4 hexagonos da base M1 tem performance registrada. Esta é uma validacao ESTRUTURAL e de COBERTURA — não uma validacao de resultado de negocio. Cruzar com performance real segue como o teste definitivo, e depende de dado que hoje não existe na base.
- As correlacoes hex-level são modestas por natureza (valores brutos por hexagono são ruidosos e assimetricos). No agregado municipal, o alinhamento satellite-Censo já foi validado em $r = 0,86$ (3.892 municipios) e $r = 0,96$ em Goiania — vide Relatorio Nacional.
- A ACELERACAO (crescimento recente vs inicial) só está medida onde existe a serie de 8 anos (RM de Goiania + DF). A aquisicao temporal das demais UFs está pendente — é o proximo passo e não bloqueia nada do que está entregue aqui.

8. Conclusao — qual é o ganho real

O satellite não substitui o M1: ele preenche os dois buracos estruturais do M1.

- GANHO 1 — RESOLUCAO. O M1 opera em 3.892 municipios; o satellite, em 486.850 hexagonos (125x). Isso recupera 68,2% da variacao de densidade e 76,8% da variacao de crescimento que hoje são invisiveis.
- GANHO 2 — TEMPO. O baseline é uma foto do Censo 2022. O satellite entrega trajetoria 2016→2023 por hexagono, com correlacao de apenas 0,18 com o score atual: sinal novo, não redundante.
- GANHO 3 — FILA DE TRIAGEM. 39.873 candidatos ocultos já identificados e entregues em CSV, prontos para verificacao.
- RECOMENDACAO — adotar as features de satellite como CAMADA COMPLEMENTAR do M1 (não substituta): a densidade da a resolucao intramunicipal que falta, e o crescimento adiciona um criterio de priorizacao que nenhuma fonte censitaria produz. Passo seguinte: concluir a aquisicao temporal (2017-2022) para levar a ACELERACAO — 'onde a demanda ESTARÁ' — as 12 UFs.